Árvore de Decisão

Projeto

Computação Inteligente

Arthur Flor
afsn@ecomp.poli.br

Conteúdo

Introdução

No contexto de reconhecimento de escrita, o projeto utiliza a técnica Árvore de Decisão para classificar imagens de caracteres, buscando identificar qual caractere está associado à imagem.

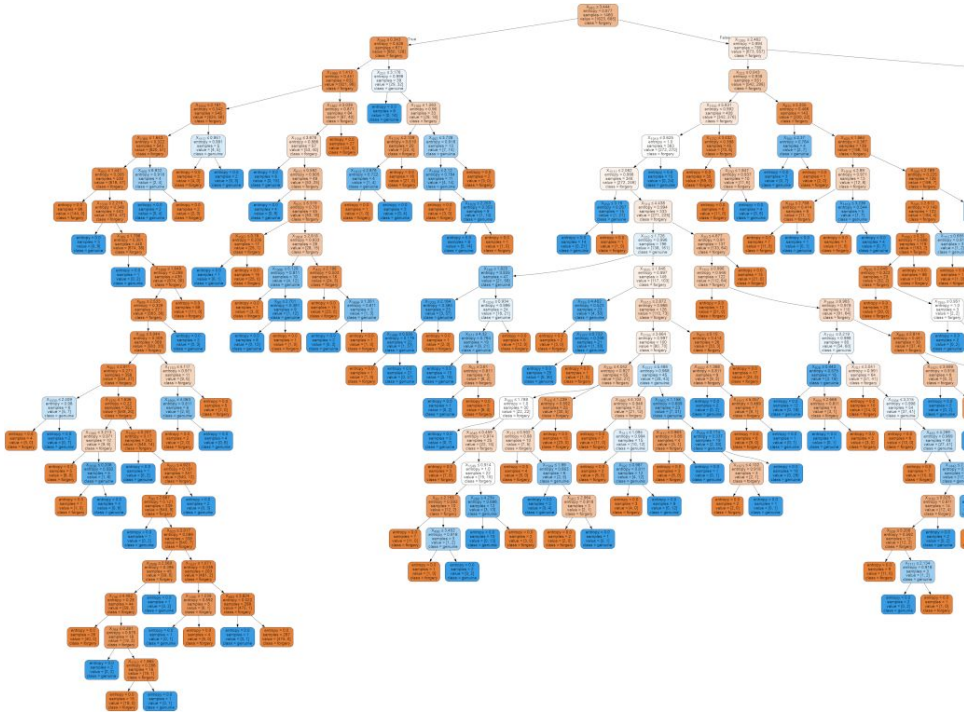

Fluxograma do Projeto

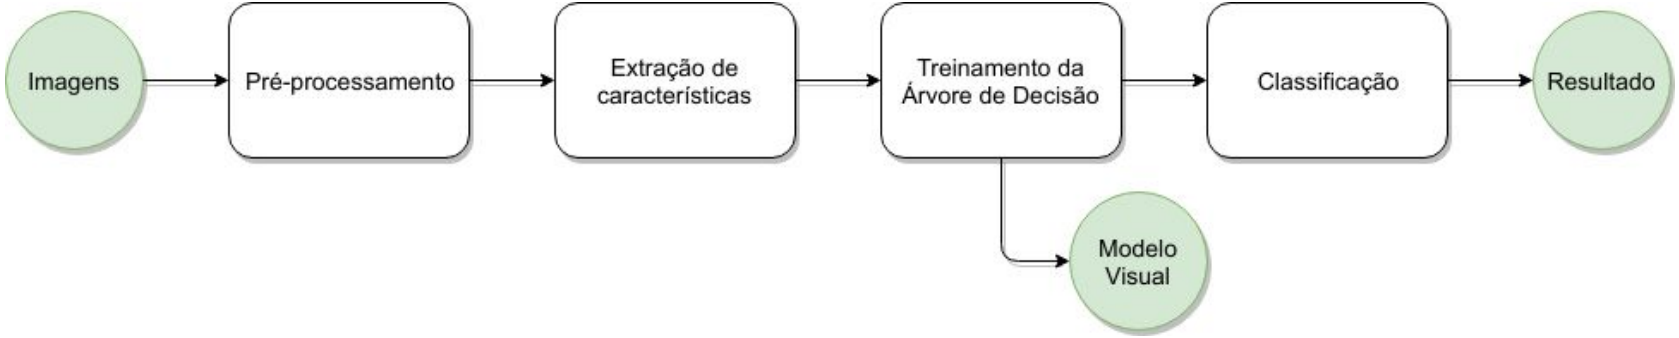

Dados Utilizados

- ➔ Chars74K image dataset - University of Surrey
- ➔ Última atualização em 2015
- ➔ 1980 imagens de caracteres (128x96 pixels)
- ➔ 36 classes (0-9, A-Z)

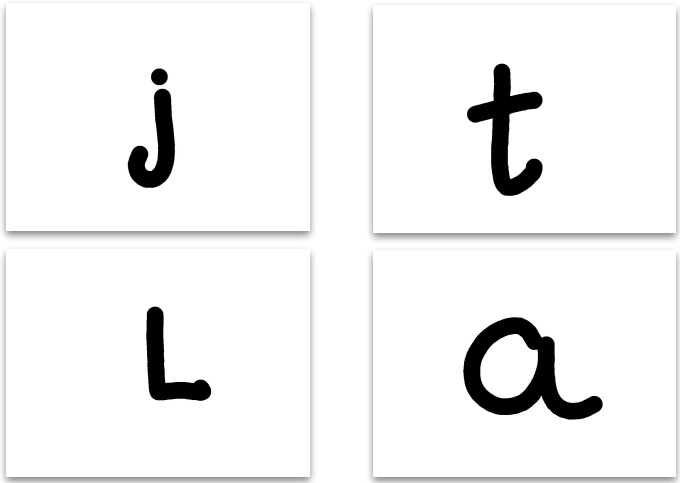

Exemplo das imagens do dataset

Pré-processamento

1. Binarização da imagem
2. Minimum Bounding Box no caractere
3. Redimensionamento da imagem para 512x512

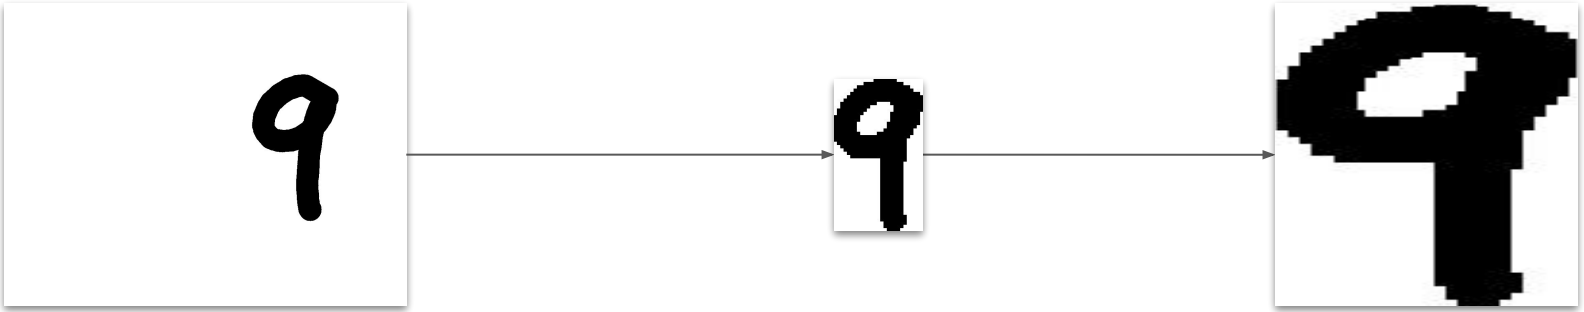

Imagem 128x96

Binarização e Minimum Bounding Box

Imagem 512x512

Extração de Características

- ➔ Momentos Invariantes de Hu (vetor com 7 características)
- ➔ Convolutional Neural Network - CNN (vetor com 2048 características)

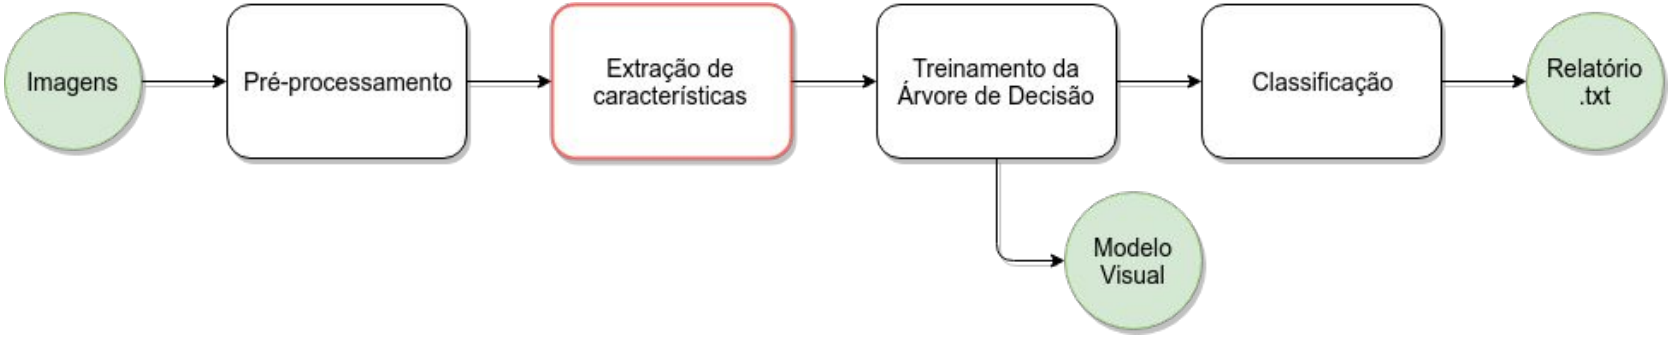

Algoritmos para Treinamento/Classificação

- ➔ Implementação manual: C4.5
- ➔ Implementação com sklearn: CART e Random Forest

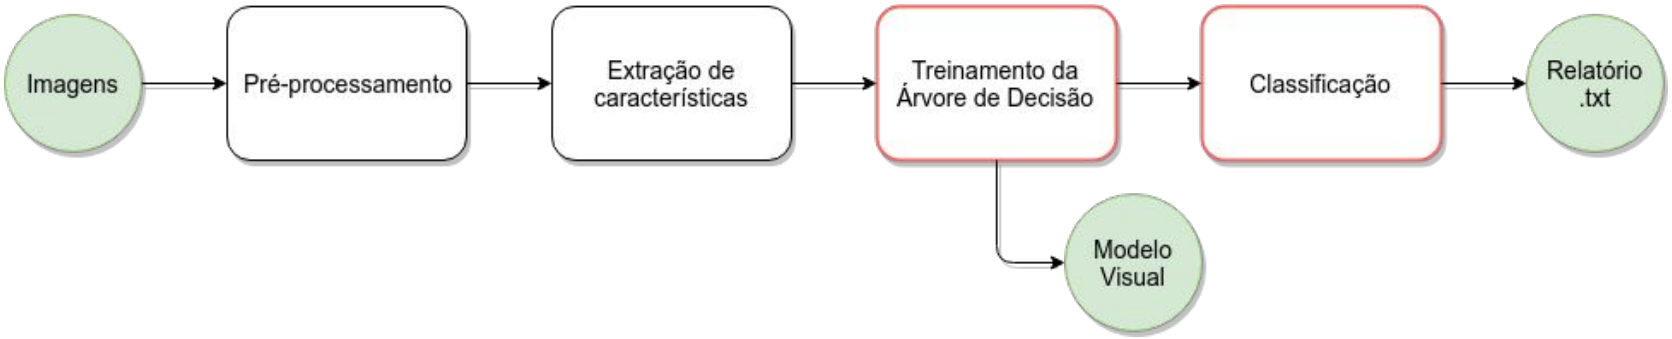

Ferramentas

- ➔ Python
- ➔ Scikit-learn
- ➔ Theano/Lasagne
- ➔ Graphviz

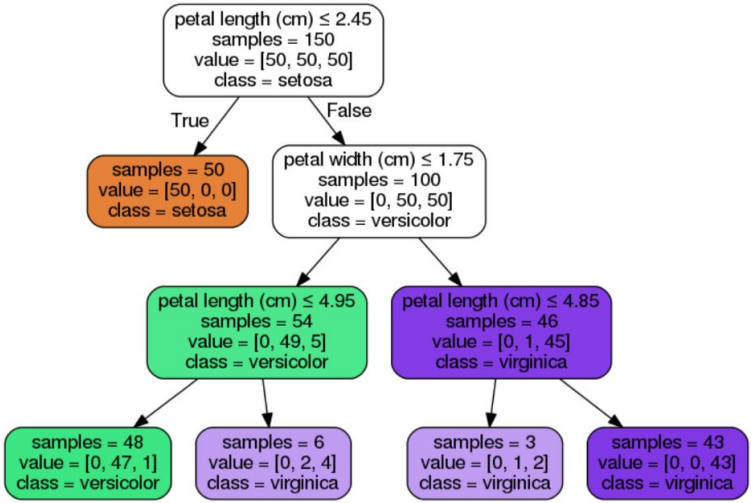

Exemplo do modelo visual gerado pela biblioteca Graphviz

Experimento

- ➔ Executar todas as combinações das técnicas de extração de características e de árvore de decisão (6 combinações);
- ➔ Dividir as imagens, de modo aleatório, em 66,67% para treinamento e 33,33% para teste;
- ➔ Realizar 30 vezes cada combinação, armazenando o tempo de execução e a taxa de acerto.

Resultados (Precisão)

Treinamento: 1320 imagens

Teste: 660 imagens

Máx:

CNN + RF (72,42%): 478/660

Mín:

CNN + CART (56,52%): 373/660

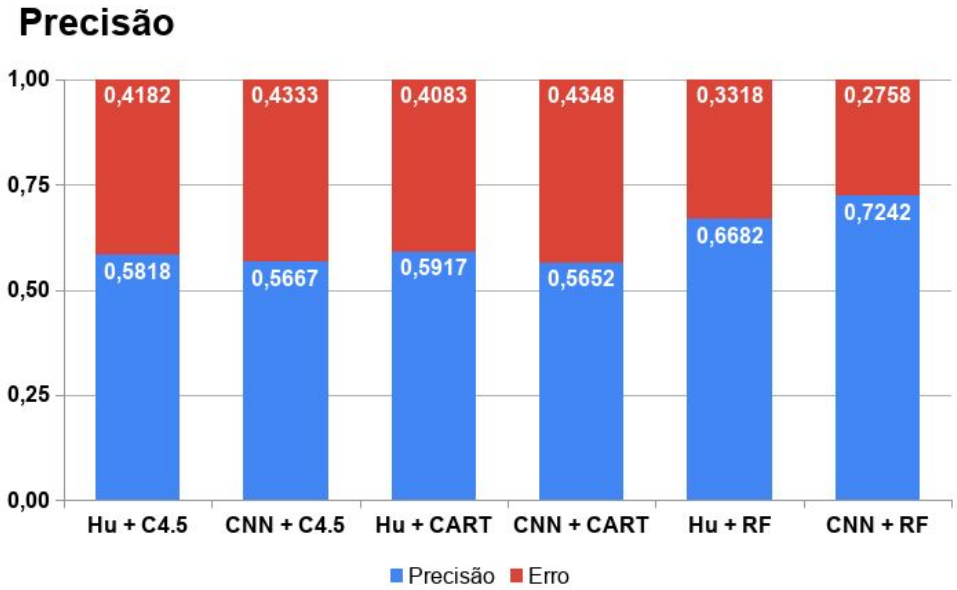

Resultados (Tempo)

Treinamento: 1320 imagens

Teste: 660 imagens

Máx:

CNN + C4.5: 380,54s

Mín:

Hu + CART: 0,05s

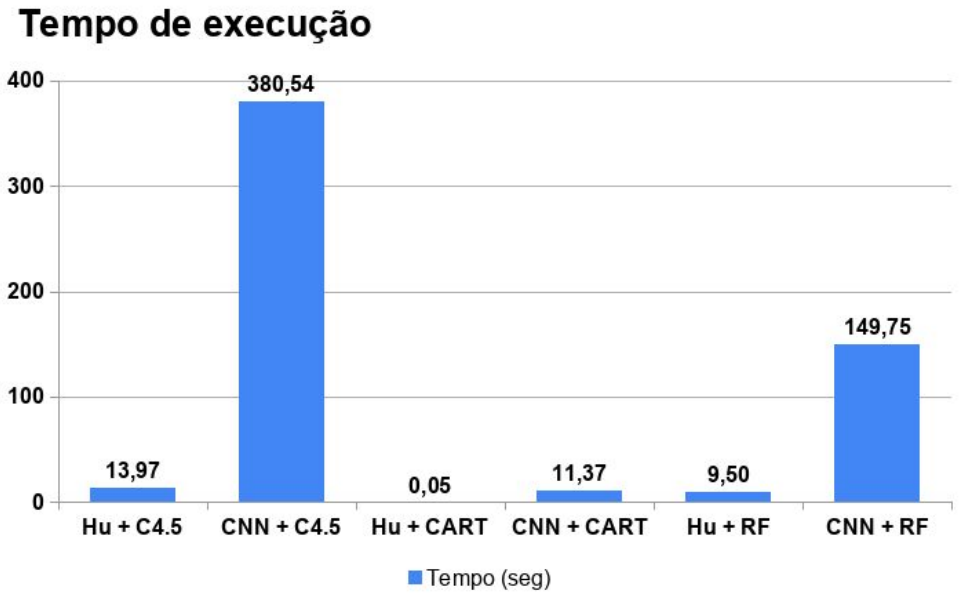

Visualização

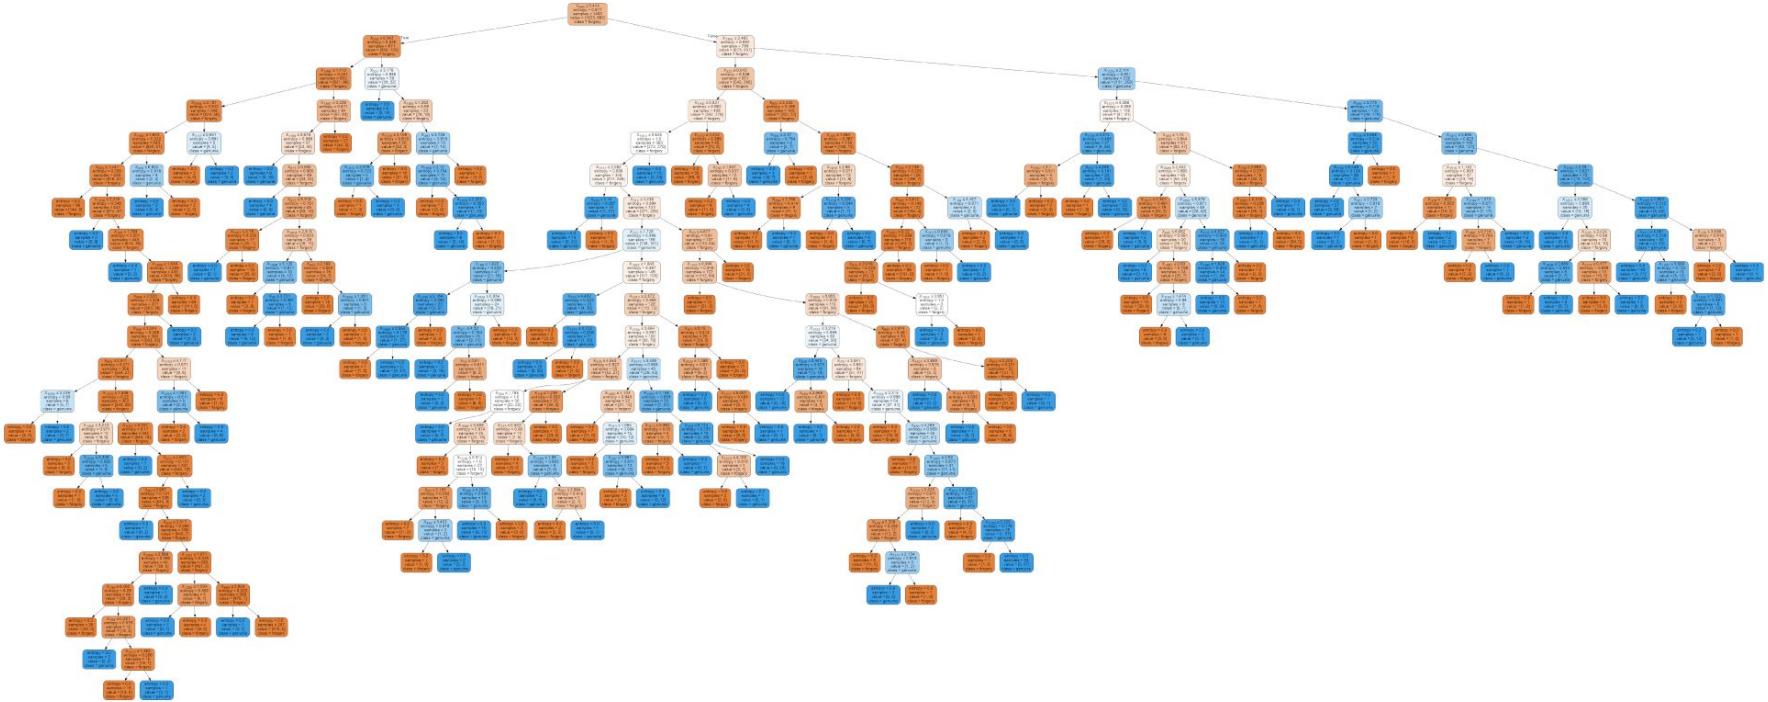

Representação visual de uma árvore da Random Forest

Conclusões

- ➔ A taxa de acerto melhora conforme o pré-processamento;
- ➔ A CNN obteve um melhor resultado, comparado aos Momentos Invariantes de Hu, quando combinado a Random Forest;
- ➔ O código implementado manualmente (C4.5) não está otimizado. Isso foi observado no tempo de execução quando combinado a CNN (input de 2048 características).

Referências

- http://www.ee.surrey.ac.uk/CVSSP/demos/chars74k/
- https://machinelearningmastery.com/implement-decision-tree-algorithm-scratch-python/
- http://scikit-learn.org/stable/modules/tree.html
- https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html
- https://medium.com/@williamkoehrsen/random-forest-simple-explanation-377895a60d2d
- https://towardsdatascience.com/random-forest-in-python-24d0893d51c0